# Qwen3.8-27B 推理优化

单张 RTX 4090 48GB · SGLang 0.5.22 · DFlash2 投机 · 手写 sm_89 FP8 算子

官方 AIPerf 8192/512，每档 100 请求，零错误：

| c1 | c2 | c4 | c8 | |
|---|---|---|---|---|
| **138.99** | **190.98** | **234.42** | **254.39** | tok/s |

IFBench prompt_level_strict 0.83（门槛 0.76）· 400 请求零错误 · 三条命令复现

# 项目概述：赛题给了什么，我们交出什么

问题不是“能不能跑”，而是同一张卡上把 27B 的解码链路压到可用吞吐。

## 赛题给的硬条件

模型固定 `qwen3.8-27b-fp8`：29 GB 权重，官方 E4M3 $128 \times 128$ 块量化。

- 单张 RTX 4090 48GB（49 140 MiB），driver 610.57.04
- AIPerf 8192/512，c1/2/4/8 各 100 请求 + 8 预热
- IFBench 100 题，`max_tokens=32768`，指标 `prompt_level_strict`
- 公开口径、无盲测；但赛后二次复验，复现不出取消成绩

## 我们交出的东西

一条命令起服的 SGLang 0.5.22 服务：投机解码 + 手写 FP8 算子链 + FP8 KV 与显存重分配。

| 指标 | 提交配置 |
|---|---|
| 官方四档输出吞吐 | **138.99/ 190.98/ 234.42/ 254.39** tok/s |
| 错误请求 | **0 / 400** |
| c1 TTFT / c8 TPOT P50 | 1.569 s / 20.55 ms |
| IFBench / 峰值显存 | 0.83 / 47 338 MiB |

性能在 C 机、IFBench 在 A 机；跨机只比趋势。

同机同口径起点 = draft 8 + Triton 的 106.24/152.11/192.38/215.88 tok/s；全文不跨机、不跨请求数换算倍数。

# 问题与目标：48 GB 是一张要逐笔结算的账

显存不是靠“省”，是靠把省下的每一 GB 换成草稿深度和 KV 容量。

| 项 | 占用 | 处理 |
|---|---|---|
| FP8 权重 | 29 GB（实测 27.24） | 赛题固定，不再量化 |
| DFlash2 草稿 | 3.85 GB | 保留：换 c1 +46% |
| 草稿回滚状态 | 0.63 GB/草稿 token | ReplaySSM 紧凑窗口约 2 GB |
| BF16 lm_head | 2.5 GB | 在线转 FP8 → 1.2 GB |
| 视觉塔 | 0.92 GB | 不加载 |
| HTTP 父进程 | 454 MiB | 移出 GPU |
| KV + 状态 | 合计约 15 GB | `mem 0.92` 已是上限 |

红色为本项目改动，其余为固定项。

## 为什么这值得做

一次 decode 要读完 29 GB 权重，带宽约 1008 GB/s ⇒ **29 ms/步**是带宽下限，只能减步数而不是减读取。

8 路满载 KV 需 $\geq 69\,632$ token；默认 Mamba 池只有 15 槽、每请求 5 槽，一行 warning 就把并发**静默限到 3**。

`mem` 再高，prefill 瞬时需要的约 2.2 GB 空闲就没了，启动即 OOM。

## 成功标准

四档零错误；IFBench $\geq 0.76$；60K 输入可用且 8 路长稳显存不增长；三条命令可复现。

# 整体方案：六个瓶颈，每个都带一句证据

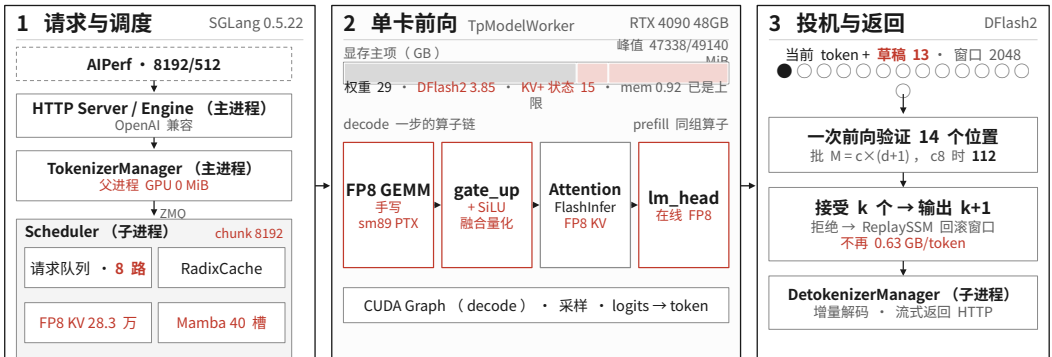
顺序是 profile 排出来的：带宽 → 算子 → 并发 → 权重 → 流量 → 状态。

| 瓶颈 | profile / 日志证据 | 改动 | 实测 |
|---|---|---|---|
| 解码带宽 | 29 GB ÷ 1008 GB/s = 29 ms/步 | 投机 draft 13 | c1 69.62 → 101.52 |
| GEMM | 8K prefill 占 73.8% | tile 自动调优 | 四档 +23/16/15/14% |
| Mamba 池 | 15 槽，并发静默限到 3 | 扩到 40 槽 | c8 103.84 → 137.77 |
| lm_head | 唯一 BF16 的 2.5 GB | 在线转 FP8 | 省 1.27 GB，KV +41% |
| 激活流量 | 单层 MLP 激活走 1.86 GB | 融合 MLP | 10.97 → 9.25 ms |
| 回滚状态 | 0.63 GB/草稿 token | ReplaySSM | KV 123 585 → **283 423** |

**方法线：**一次只改一个变量 → 同机同客户端 A/B → 官方 100 请求定取舍（20 请求只定方向）→ IFBench 门禁 → keep/reject 全部记账。

# 核心实现：一次请求走过的链路

红色为本项目改动，其余是 SGLang 官方组件与默认值。




请求 → TokenizerManager（主进程，GPU 0 MiB）→ Scheduler（子进程：8 路、chunk 8192、**40** 槽 Mamba、FP8 KV **283 423** token）→ 单卡前向（手写 FP8 GEMM → 融合 gate_up+SiLU→ FlashInfer attention → 在线 FP8 lm_head）→ 一次前向验证 **14** 个位置（c8 批 $M = 112$）→ 接受 $k$ 个输出 $k+1$，拒绝回滚 GDN 状态 → Detokenizer 流式返回。

# 为什么草稿深度停在 13，而不是更深

草稿是 c1 最强的杠杆，但验证批 $M = c \times (d+1)$ 一超出 decode tile 覆盖，高并发立刻回吐。

| 草稿/验证 | 批 M | c1 → c8 | 结论 |
|---|---|---|---|
| 10 / 快照 | 88 | 131.79 → 249.76 | 状态吃 KV |
| 10 / ReplaySSM | 88 | 133.73 → 254.85 | KV 翻倍 |
| **13 / ReplaySSM** | **112** | **141.91 → 255.26** | **四档最均衡** |
| 16 / ReplaySSM | 136 | 148.23 → 234.98 | 超覆盖，c8 −8% |

A 机、每档 20 请求：只用同表定深度。

服务日志采样：平均接受长度 **8.6–8.9**、接受率 **0.63–0.66**。$M = 136$ 超出 tile 覆盖的 128，引擎按“最近的 $M$”取了 prefill 配置——深度选择被算子配置反向约束。

## 草稿模型怎么选

| 草稿 | c1 | c8 | 接受率 |
|---|---|---|---|
| 内置 MTP4 | 69.62 | 184.41 | — |
| DSpark blk7 | 93.56 | 202.53 | 0.726 |
| **DFlash2** | **101.52** | **203.25** | 0.715 |

同机官方 100 请求（draft 8 时代的横向对比）。

## 正确性怎么兜住

ReplaySSM 只换回滚方式，不改输出分布：验证步数深探到 2800 token，**75/76** 与快照路径一致；同机重启逐 token 相同。

止损线：draft 12 的 c1/c2 更高，但 c8 接受率掉到 0.53–0.66、c8 只剩 214.96。

# 为什么调整 tile：它一次影响三个量

4090 上两个引擎都没有 4090 配置，全部吃默认 BLOCK_M=64。

## 机制

- **行补齐浪费**。`offs_am % M` 把行数补满 tile：投机单路只有 $M = 5$，仍按 64 行算 ⇒ 白算 **12.8**×。
- **并行度**。CTA 数 $= \lceil M/B_M \rceil \times \lceil N/B_N \rceil$；$M$ 小时块数填不满 SM，只能靠 `SPLIT_K` 沿 K 拆。
- **片上流量**。$B_K$、`GROUP_M`、stages 决定 SMEM 占用与 L2 命中，也就是 cp.async 能否喂满张量核。

`SWAP_AB` 可把 $M$ 维降到 8，但 SGLang 把它硬编码成 sm90 专用——补丁解除后才拿得到。

## 怎么调：带门禁的搜索，不是手调

默认 tile 作 reference → 先过正确性（相对误差 $\leq 1e{-}3$）→ 同进程计时 → 超噪声阈值 1.5% 才晋升。

| 形状 | 默认 | 调优后 | 提速 |
|---|---|---|---|
| N=5120, K=6144 | 0.113 | 0.068 | **1.66**× |
| N=14336, K=5120 | 0.122 | 0.076 | **1.61**× |
| N=5120, K=17408 | 0.214 | 0.154 | 1.39× |
| N=34816, K=5120 | 0.298 | 0.248 | 1.20× |

单位 ms，$M = 5$；服务级同机 100 请求 **四档** +23/16/15/14%。

# 锚点必须跟住服务真实出现的 $M$

引擎按“最近的 $M$”取配置，所以网格的价值不在密度，而在是否覆盖运行时真会碰到的批形状。

| 代 | 补了什么锚点 | 算子级 | 服务级（同机同口径） |
|---|---|---|---|
| 一 | 小 $M$：5/10/20/40/64 + SWAP_AB/SPLIT_K | $M=5$ 五形状 1.15–1.66× | 官方四档 +23/16/15/14% |
| 二 | $M=9/72$（draft 8 时 $c\times 9$） | $M=72$ 最高 1.56×；decode GEMM 合计约 −14% | c8 +3.6 ∼ 6.7%、TPOT 33.54 → 31.00 ms；c1 −3.1% 在噪声内 |
| 三 | $M=11\sim 88$（draft 10 时 $c\times 11$）+ lm_head | 1.02–1.44× | 吞吐变化落在噪声内，只有 c8 TPOT 24.78 → 22.74 ms 可信 |

## 教训一：$M\approx 4096$ 被误判成 decode

$M\approx 4096$ 离 40 比离 8192 更近，prefill 于是误用 decode tile：chunk 4096 时 TTFT **1.9 s → 3.6 s**。补 $M=256$ 锚点后，128–16384 的 TTFT 恢复线性。这是 unseen-shape 检查发现的，不是性能测试。

## 教训二：decode 已被 HBM 带宽限制住

三代把算子级推到 1.02–1.44×，服务级吞吐却进不了噪声区间，只有 TPOT 可信。**这条结论决定了后面两个方向：**减步数（草稿深度 + ReplaySSM）与少搬数据（融合 MLP、GDN），而不是继续磨 GEMM。

# 手写 sm_89 PTX GEMM：三条规则决定成败

这三条错了结果依然完全正确，只是慢——正确性测试发现不了，只能靠持续满载计时。

## 四条规则，一条比一条隐蔽

| 版本 | vs Tri | 原因 |
|---|---|---|
| 首版：线性 SMEM | 0.40× | 32 lane 散在 32 条 line |
| 每条盖 4 条 128B line | 0.65–0.70× | 剩 8 路 bank 冲突 |
| 加 `K_SW128` | 1.04–1.11× | `chunk ^= row & 7` |
| 搜索约 100 组 | **1.07–1.09**× | `ptxas -O1` 优于 -O3 |

$M = 8192$，450 W 持续满载，五个形状。

比 Triton 多做的：软件流水把缩放插进最后一个 K32 步；FP 指令 $64 + 64$ 减到 $8 + 64$；去掉 scale 广播的第二次 barrier；tile $128^3$ 使每 MAC 片上流量少 33%。

## 真正的约束是功耗，不是占用率

两版满载都顶在 **450 W**；纯张量核峰值只要 259 W，多出的约 190 W 全在搬数据。同功耗下 64 行 tile 约 2535 MHz、128 行约 2655 MHz ⇒ 比的是**每 MAC 能耗**。手写 GEMM 实测 **318 TFLOPS @ 2655 MHz**、占用率约 92%。

## 少搬数据：融合 MLP 与 GDN prefill

`down_proj` 的量化分组 128 正好等于 tile 的 $N$，一行 scale 在 block 末就已知 ⇒ 一个 kernel 做完 GEMM、`silu(gate)*up`、FP8 量化：**10.97 → 9.25 ms**，单层激活 **1.86 → 0.14 GB**。

GDN 同理：conv 直写连续缓冲、o 并进 h kernel，单层 **3.07 → 2.165 ms**，一次 8K prefill 1582 → 1532 ms。

# 结果与证据：同机逐层叠加，每一行都能对上

C 机，官方 AIPerf 8192/512，每档 100 请求 + 8 预热，六档全程零错误。

| 配置（逐行叠加） | c1 | c2 | c4 | c8 | c1 TTFT | c8 TPOT |
|---|---|---|---|---|---|---|
| draft 8 + Triton（同机起点） | 106.24 | 152.11 | 192.38 | 215.88 | 1.819 s | 28.01 ms |
| + 手写 GEMM | 108.24 | 157.00 | 198.09 | 222.96 | 1.733 s | 24.16 ms |
| + 融合 MLP / draft 10 / 去视觉塔 | 122.16 | 168.96 | 210.87 | 234.98 | 1.643 s | 24.78 ms |
| + 第三代 tile | 122.26 | 170.33 | 208.41 | 237.84 | 1.640 s | 22.74 ms |
| + tile 优先 / FP8 草稿 / d13 | 137.65 | 182.99 | 220.39 | 243.98 | 1.606 s | 20.67 ms |
| **+ GDN 融合 / ReplaySSM（提交）** | **138.99** | **190.98** | **234.42** | **254.39** | **1.569 s** | **20.55 ms** |

第四行吞吐变化在噪声内（c4 −1.2%、c8 +1.2%），照登不修饰。

## 相对优化前（口径已标）

**同口径**：tile 调优前 56.46/91.10/129.22/161.29 → +23/16/15/14%，均 100 请求。

**引擎原样**：vLLM 无投机 18.28/36.71/64.25/64.46，**每档仅 20 请求**，只作参考。

## 可信度

400 请求零错误；错误请求不剔除，原始记录随仓库提交。

同机重复波动 0.06/1.3/0.08/0.4%；跨卡差约 4% ——比较一律同机。

## 两个禁止互比的数

长稳 1000 请求用随机 token-ID 输入，**196.37 不能与 254.39 同表**。

演示启动（240K、带 metrics、允许截断）**不是提交配置**，不进结论。

# 质量：0.83 过线，以及 17 道失败题里 6 道怎么败

评分规则明确要“分析失败案例”。结论：主因是输出分隔符与判分方式的交互，不是优化引入的。

| 指令类型 | 题数 | 原因 |
|---|---|---|
| no_bullets（95–99） | 5 | 内容合规，败在**响应开头的空行** |
| line_indent（80） | 1 | 同上 |
| line_indent（74–79） | 6 | 阶梯文本被放进代码块，围栏行不满足逐行递增 |
| line_indent + ratio（81） | 1 | 思考段约 9 万字符，耗尽 32768，正文为空 |
| 其他（11/37/64/88） | 4 | 关键词位置、标点计数、原样重复、分隔符各 1 |

**根因：**`qwen3` reasoning parser 把 `</think>` 之后的 `\n\n` 留在 `content` 里——100 条输出有 **99** 条以它开头。这两个 checker 逐行检查，开头空行直接判失败；宽松判定会先去掉首行，所以这 6 题宽松全过。

| 用官方 checker 重判 | 原样 | 去开头换行 | 变差 |
|---|---|---|---|
| 提交配置 | 83 | 89 | **0 题** |
| vLLM + MTP3 | 78 | 85 | **0 题** |

原样重判与官方分数逐题一致，说明重判方法可信。

我们没有改这一行为，官方成绩仍记 0.83；89 只是重判数字，不当成绩用。

### 为什么说与优化无关

四套配置逐题对比：13/17 题在全部 4 次运行里都失败；vLLM + MTP3（**无手写 kernel、无 tile 调优**）与提交配置**共同失败 16/17 题**。

IFBench 采样生成、100 题波动约 ±4 **个百分点**，**我们不用它证明任何提升**。

# 工程化：为“赛后二次复验”而设计

复现不出会取消成绩，所以提交物里每个数字都要能回到原始记录。

## 三条命令

```
bash scripts/setup_sglang_48g.sh
bash scripts/run_sglang_48g.sh
bash docs/eval/run.sh \
 --base-url http://127.0.0.1:30000/v1 \
 --model qwen3.8-27b-fp8 --mode all
```

空环境到服务约 3 分钟；官方全量（400 请求 + IFBench）19 分 34 秒。`SGLANG_FP8_HAND_GEMM=0` 一键退回 Triton，“手写带来多少”当场可 A/B。

## 版本与快照

SGLang 0.5.22 · torch 2.14.1；VERSION 记 commit hash，80 个权重文件带 sha256。

## 补丁与证据链

7 个补丁按固定顺序施加且**幂等**，每个留三重回退，任一失效服务仍能起；51 个运行目录里逐请求 jsonl 与 summary 同目录，`EVIDENCE_INDEX.md` **由脚本读 summary 生成而非誊抄**。

## 复验容差与排查顺序

| 项 | 判据 | 对不上时先查 |
|---|---|---|
| 同机吞吐 | ±3% 视为复现 | 是否同机、请求数 100 |
| 跨卡吞吐 | ±4 ～ 6% | 补丁是否全部施加 |
| TPOT / 错误数 | ±10% / **须为 0** | `draft · mem · context` |
| IFBench | ±0.04 | 是否误用演示启动命令 |

**稳定性**：长稳 c8 1000/1000、43.5 min，显存恒定 **47 338 MiB** 无 OOM；32K 输入 TTFT 7.345 s、60K 16.457 s。

# 成本与取舍：450 W 是唯一的“价格”

长稳实测均值 443.1 W（88 次采样）已顶到 450 W 上限，所以取舍只看每 token 花掉多少 GPU 时间。

| 指标 | 提交配置 |
|---|---|
| 每百万输出 token GPU 时 | c1 2.00 h / c8 1.09 h |
| 每输出 token 能耗 | c8 1.74 J（按实测 443.1 W） |
| 同上，c1 | 3.24 J（按 450 W 上界） |
| GEMM 实测 | 318 TFLOPS @ 2655 MHz |
| 峰值显存 / 上限 | 47 338/ 49 140 MiB |

c1 未单测功耗，按 450 W 上限给上界。

c8 每 token 成本约为 c1 的一半：并发把每次权重读取摊给更多请求。

**当前瓶颈：**GEMM 占 prefill 73.8% → 81%，不是 GEMM 变慢，是别的时间被消掉——GDN 融合后其余只剩 294 ms。

## 关键取舍：每行都写判据

| 选择 | 换来 | 付出 / 止损判据 |
|---|---|---|
| 草稿 8→10→13 | c1 69.62→141.91 | 3.85 GB；接受率跌到 0.63 就停 |
| ReplaySSM | KV 123 585 → 283 423、c8 +2.0% | c1 0.976×；75/76 一致才用 |
| FP8 lm_head | 省 1.27 GB、KV +41% | 误差 $1e{-}7$，IFBench 不变 |
| 关 prefill 图 | 腾出瞬时约 2.2 GB | GPU 已 99.4% 忙碌，重开无收益且 OOM |
| tile 优先于深度 | 转置布局换来 draft 13 | $M$ 覆盖要重补锚点（三代即为此） |

**否决清单：**W4A8/FP4 整体 0.967×、后半程 0.804×；draft 16 超覆盖 c8 −8%；chunk 4096 使 TTFT 变差；GDN 分段省 0.7 GB 但 TTFT +4%；改时钟容器内不生效。

# 总结与不足

已完成的目标，和下一步真正该做的两件事。

## 已完成

官方四档 **138.99/ 190.98/ 234.42/ 254.39** tok/s，400 请求零错误。

同机逐层叠加可对账：相对 draft 8 + Triton 起点 $+31/26/22/18\%$。

IFBench **0.83** $\geq 0.76$，17 道失败题逐题归因。

47 338 MiB 恒定，长稳 1000 请求零错误；60K 输入可用。

三条命令复现，哈希与逐请求原始记录齐备。

## 未解决（按余量排序）

 **prefill 只剩 294 ms 可动**：GEMM 已顶功耗墙（318 TFLOPS、占用率 92%），继续磨 GEMM 不会有服务级收益——本轮最贵的一条结论。

 **decode 受 HBM 带宽限制**：算子级 $1.02 \sim 1.66\times$ 大多到不了服务级，只有 TPOT 可信。

 **tile 的 $M$ 覆盖不完整**：draft 16 的 $M = 136$ 仍落到 prefill 配置；lm_head 仍走 Triton，每步约 0.2 ms 未省。

 **官方口径只跑了 1 轮**；sm_89 不在官方验证矩阵是我们自选的风险，用质量门禁与长稳承担。

**下一步：**把 GDN 与 attention 的中间缓冲彻底不落显存；补全 $M$ 覆盖后重开草稿深度扫描；服务运行时按实际 $M$ 分布自动再调优。

代码、配置、补丁、原始逐请求结果与三份报告同仓提交；现场若使用不同版本会主动说明。

谢谢，欢迎追问。