1 请求与调度

SGLang 0.5.22

AIPerf · 8192/512

HTTP Server / Engine （主进程）
OpenAI 兼容

TokenizerManager （主进程）
父进程 GPU 0 MiB

ZMQ

Scheduler （子进程） chunk 8192

请求队列 · **8 路**

RadixCache

FP8 KV 28.3 万

Mamba 40 槽

2 单卡前向

TpModelWorker

RTX 4090 48GB

显存主项（GB）

峰值 47338/49140 MiB

权重 29 · DFlash2 3.85 · KV+ 状态 15 · mem 0.92 已是上限

decode 一步的算子链

prefill 同组算子

FP8 GEMM
手写
sm89 PTX

gate_up
+ SiLU
融合量化

Attention
FlashInfer
FP8 KV

lm_head
在线 FP8

CUDA Graph （decode） · 采样 · logits → token

3 投机与返回

DFlash2

当前 token + **草稿 13** · 窗口 2048



一次前向验证 14 个位置
批 M = c×(d+1)， c8 时 **112**

接受 k 个 → 输出 k+1
拒绝 → ReplaySSM 回滚窗口
不再 0.63 GB/token

DetokenizerManager （子进程）
增量解码 · 流式返回 HTTP